

第三章 基于 Yolov11 的微小无人机检测架构设计与实现

本章作为全文的核心理论内容，重点论述针对远距离与高机动无人机目标识别算法的架构设计与底层实现过程。本章首先重点分析了基准检测模型的基础理论及其在微小目标探测场景下暴露的性能缺陷，随后详细阐述基于上下文锚点注意力 CAA^[16]的首次特征增强方案，在此基础上，本章全面推演所构建的高性能检测架构 YOLOv11n-MEDA 在多头拓扑重构、空间特征保真、高频边缘增强与难例回归优化等维度的原理机制，并最终通过严密的定量实验数据论证各项算法重构策略的实际成效。

3.1 Yolov11 检测原理与无人机探测的物理缺陷

Yolov11 延续并深化了单阶段目标检测器的高效设计哲学，其主干网络通过大量堆叠 C3k2 与 C2PSA 模块，利用跨阶段局部网络思想实现了梯度的深度流动与特征的有效提纯。然而，当将该基准模型直接应用于开阔复杂环境下的无人机探测任务时，其固有的网络拓扑与算子特性会有较明显的物理局限性。

首先是特征剥落现象，根据卷积神经网络的感受野与下采样原理，Yolov11 的最小检测头 P3 层经历了像素步幅达八倍的缩减。对于在极端远距离下进行侦测的摄像机画面而言，无人机在 640×640 的图像中往往仅占据不足 8×8 像素的微小面积。这意味着当该目标的图像特征历经层层卷积传入 P3 层时，其有效特征响应面积将不足 1×1 像素。这种连续的跨步卷积与池化操作会导致极小目标的语义特征在深层网络中被平滑与抹除，进而导致系统在远距离预警时漏检率急剧增加。

除了静态条件下的特征丢失，无人机的高速机动性也给视觉检测带来了另一困难，即动态模糊。在实际追踪过程中，由于摄像机的快门曝光时间以及目标的高速横切运动，无人机的旋翼和机架在画面中不可避免地会产生严重的拖影。这种视觉上的模糊在图像频域中等效于一个强烈的低通滤波器，它极大地削弱了图像中的高频边缘信号。由于常规卷积核高度依赖锐利的像素梯度变化来精确定界目标轮廓，高频信号的衰减会导致边界框回归损失函数难以平稳收敛，在最终的视频流输出中便表现为检测框的剧烈抖动与闪烁。

3.2 基于 Yolov11 的基线模型前期优化与验证

3.2.1 基于 CAA 机制的全局特征增强

在课题研究初期，为了增强模型在城市楼宇、树林等复杂低空背景下的特征判别力，本文首先尝试在 Yolov11 基准模型中引入上下文锚点注意力 CAA (Context Anchor Attention) 模块^[16]。在传统的视觉注意力机制中，全局自注意力虽然能够捕获极长距离的像素依赖，但其计算复杂度随特征图分辨率呈平方级增长，显然无法满足无人机边缘计算平台的实时性需求。鉴于此，CAA 模块的设计初衷在于利用极轻量化的卷积算子，高效捕获目标的远程空间依赖关系，以此抑制背景杂波。在特征处理的首个环节，CAA 模块摒弃了直接对全局特征进行运算的做法，而是引入了“局部锚点”的概念。具体而言，输入特征 X 首先经过一个核大小为 7×7 、步长为 1 的平均池化层进行处理。这一操作在物理意义上等效于一个抗混叠的低通滤波器，它在保留局部区域代表性特征的同时，有效滤除了高频的杂乱背景噪声，生成了平滑的锚点特征 X_{pool} ：

$$X_{pool} = AvgPool_{7 \times 7}(X) \quad (3-1)$$

为了在不显著增加参数量的前提下扩大感受野，CAA 创新性地采用了一维条带卷积来替代传统的方形大核卷积。对于带有细长旋翼和机臂的十字形或 X 形无人机目标，水平与垂直方向的结构化特征尤为关键。模块分别利用水平方向的 1×11 卷积与垂直方向的 11×1 卷积，沿正交方向逐级提取长距离的上下文信息。这种将 11×11 的二维感受野解耦为两个一维向量叠加的数学操作，不仅极大地缩减了计算冗余，更精准契合了无人机的物理轮廓分布：

$$F_h = BatchNorm(Conv_{1 \times 11}(X_{pool})) \quad (3-2)$$

$$F_v = BatchNorm(Conv_{11 \times 1}(F_h)) \quad (3-3)$$

在完成感受野的十字形扩展后，特征张量被送入一层 1×1 逐点卷积，并利用 Sigmoid 激活函数 σ 将数值映射至 $[0,1]$ 区间，从而生成空间注意力权重矩阵 A_{CAA} 。最终，将该权重矩阵与原始特征 X 进行逐元素相乘，完成特征的重标定：

$$A_{CAA} = \sigma(Conv_{1 \times 1}(F_v)) \quad (3-4) \quad X_{out} = X \otimes A_{CAA}$$

在具体的网络嵌入策略上，本文并未对 Yolov11 的宏观拓扑结构进行修改，而是将 CAA 模块作为一种即插即用的特征提纯单元，选择性部署于主干网络 Backbone 的多个关键节点处。具体而言，在每个 C3k2 基础特征提取模块之后，系统均串联了一个 CAA 轻量化注意力层。这一设计使得网络在完成局部卷积特征提取后，能够立刻通过 CAA 模块的十字形条带卷积与 Sigmoid 重标定机制，对特征

图进行全局上下文的二次加权。

从特征流向的角度来看，输入图像在历经逐级下采样的过程中，CAA 模块在不同尺度层级上持续发挥着“背景抑制滤波器”的作用：在浅层，它帮助网络排除杂乱的地面纹理干扰，聚焦于无人机的几何轮廓；在深层，它利用扩大的感受野捕捉无人机与周围环境如楼宇、树枝的空间依赖关系，从而进一步降低虚警概率。这一阶段的初步验证在不显著增加计算开销的前提下，有效增强了基线模型对复杂低空背景的判别鲁棒性，为后续更深层次的架构重构提供了特征可视化经验。




图 3-1 CAA 网络结构图




图 3-2 Yolov11 引入 CAA 注意力模块的网络结构图

3.2.2 引入 Focaler-IoU 的回归损失优化

在引入 CAA 模块后，尽管模型对背景噪点的抵抗力有了明显改观，但由于条带卷积极大地扩展了感受野，导致模型在预测边界框时出现了微弱的定位偏移，即在高 IoU 阈值下的贴合准确率出现了退化。为弥补这一定位精度的损失，本文在损失函数环节进一步引入了 Focaler-IoU，该函数创新性地提出了一种基于线性区间映射的难易样本加权策略^[18]。设原始交并比为 IoU，其映射机制的数学定义为：

$$IoU_{focaler} = \begin{cases} 0, & IoU < d \\ \frac{IoU - d}{u - d}, & d \leq IoU \leq u \\ 1, & IoU > u \end{cases} \quad (3-5)$$

通过人为设定上限阈值 u 和下限阈值 d ，Focaler-IoU 重塑了交并比的分布曲线。该策略强制模型在训练后期放弃对极易样本的过度优化，转而将梯度深度聚焦于那些处于特定区间内的困难样本，如难以严密贴合的机翼边缘。这一补偿机制在保障整体召回率的同时，有效提升了边界框的几何贴合度。然而，综合实验表明，仅靠注意力机制与损失函数的外部修补，依然无法从根本上改变极端远距离目标的特征剥落趋势，这促使了本文向更深层的网络架构进行设计重构。

3.3 YOLOv11n-MEDA 架构设计与实现

在完成前述的特征增强验证后，实验数据表明单纯依赖外部模块叠加与损失函数替换，极端远距离目标在多次下采样中空间分辨率不可逆衰减的趋势无法改变。为突破微小目标深层特征剥落与动态边缘模糊的感知问题，本文并未在原有基准拓扑上进行浅层模块堆砌的常规调优路径，而是跨学科借鉴了医学影像病灶提取中多尺度边缘融合框架的设计思路^[19]，并针对无人机低空高机动飞行的特有物理属性，对基线网络进行了底层的架构设计。通过解构原始的特征金字塔传递逻辑，并将高分辨率保真算子与高频残差边缘提取机制进行底层级联，本文系统地提出并实现了一种名为 YOLOv11n-MEDA 的高性能微小目标专用检测架构。




图 3-3 YOLOv11n-MEDA 网络结构图

注：Upsample：上采样；ADown：自适应下采样模块；Dysample：动态上采样模块；RepNCSPELAN4：重参数化跨阶段高效层聚合网络；EMA：高效多尺度注意力；MSEF：多尺度高效特征融合模块；

3.3.1 高保真特征传递

在宏观的网络拓扑层面，为实现高保真特征的有效传递，本文突破了常规的 P3-P5 三头检测架构。由于 P3 层经历了 8 倍下采样，远距离无人机目标到达该层时特征响应已极为微弱，因此本文额外在颈部 Neck 网络中直接引出了主干网络中的 P2 特征层，由于 P2 层仅经历了四倍的下采样，它在整个特征金字塔中保留了 160×160 （基于 640 输入）的更高分辨率空间细节，通过将该层级与深层富含语义的特征流进行上采样融合，构建了一个极小目标的检测通道，形成了覆盖 P2-P5 的四头尺度架构。

伴随高分辨率特征层的引入，如何确保特征在不同尺度间缩放时的信息保真度显得尤为关键。在传统的卷积神经网络中，特征图的空间降维通常依赖于步长为 2 的跨步卷积，但从信号采样的物理角度来看，这种单一通道的跨步滑动会直接丢弃掉原特征图中近 75% 的空间像素点。对于原本就极其微弱的远距离无人机

目标而言，这种降维方式易导致目标的核心像素被滑动窗口跳过，从而造成不可逆的结构性信息破损。为了解决这一信息传递困难，本文在特征的下采样环节引入了 ADown 双分支高保真算子。与传统单路卷积不同，ADown 算子采用了空间与语义解耦的并行提取策略，即设输入特征张量为 X ，该模块首先利用平均池化操作作为抗混叠的低通滤波器，在抑制高频背景噪声的同时，保留全局的粗略空间分布概率，生成平滑特征 X_{pool} ，随后该特征在通道维度被均分为两个子张量 X_1 与 X_2 ，左侧分支对 X_1 施加 3×3 跨步卷积，旨在深度挖掘特征的内在语义关联，而右侧分支则摒弃了可能破坏微小轮廓的大核卷积，仅利用 1×1 逐点卷积对 X_2 进行通道维度的线性映射，以此最大程度地将原始的纯粹空间几何结构直接传递至下一网络层级。

其前向传播的完整数学逻辑可严密表述为：

$$X_{pool} = AvgPool(X) \quad (3-6)$$

$$X_1, X_2 = Split(X_{pool}, \dim = 1) \quad (3-7)$$

$$Y_{out} = Concat(Conv_{3 \times 3}(X_1), Conv_{1 \times 1}(X_2)) \quad (3-8)$$

通过将这两路在物理意义上互补的特征信息在通道维度进行重新级联，ADown 机制在有效压缩特征空间维度的同时，兼顾了深层语义的提取与浅层微小目标轮廓的保真，从根本上遏制了特征剥落现象的发生。

在特征金字塔网络的自顶向下融合路径中，如何将深层低分辨率特征图进行高保真放大，是决定极小目标探测性能的关键环节。传统 Yolov11 架构通常采用最近邻插值或双线性插值等静态算子进行上采样，其仅根据像素间的几何距离进行线性加权，完全忽视了图像本身的语义内容，在处理远距离无人机目标时，这种盲目的插值过程会强行将微弱的目标特征向周围背景像素稀释，导致原本清晰的机臂或旋翼边缘产生严重的网格伪影与形态模糊。为了克服静态算子的物理局限并兼顾边缘计算平台的实时性需求，本文引入了基于点采样范式的 DySample 学习型动态上采样算子^[17]。与以往依赖高计算量动态卷积核的算子如 CARAFE（Content-Aware ReAssembly of FEatures）不同，DySample 将上采样的本质回归为非刚性坐标变换，其核心在于使得网络具有自主寻找目标边缘的能力。具体而言，该算子通过一个极轻量化的 1×1 卷积层，直接从输入特征图 X 中预测出像素级的空间偏移量映射场 O 。对于目标高分辨率网格中的每一个标准坐标点 $p \in P$ ，系统根据学习到的偏移量对其进行位置修正，生成发生形变后的采样坐标点 p' ：

$$p' = p + O(p) \quad (3-9)$$

在获得了这组具备内容感知特性的非均匀采样坐标后，DySample 利用底层高

度优化的双线性重采样函数，在原始低分辨率特征图上提取对应的像素值，从而解算出高分辨率特征图 Y ：

$$Y(p) = \sum_{q \in N(p')} X(q) \cdot G(q, p') \quad (3-10)$$

动态上采样算子本质上在特征融合阶段引入了内容感知的空间重聚合机制，在训练损失函数梯度反向传播的驱动下，网络预测的空间偏移量场能够隐式地引导采样坐标向无人机的高频边缘区域发生非刚性聚拢，涵盖旋翼交界处与机身刚性轮廓等关键物理结构。该动态自适应采样机制使得重构后的高分辨率特征图在目标边界处保持了极其敏锐的梯度响应，有效克服了深层语义在尺度放大过程中的空间量化误差与特征稀释现象，从而为后续检测头执行极小无人机目标的像素级分类与精确坐标回归提供了更可靠的特征支撑。

在特征金字塔的颈部 Neck 与检测头 Head 的设计中，为了应对多尺度特征融合带来的计算冗余，本文引入了 RepNCSPELAN4 高效聚合网络。该结构结合了 CSPNet（Cross Stage Partial Network）即跨阶段局部网络的梯度截断思想与 ELAN（Efficient Layer Aggregation Network）即高效层聚合网络的架构优势。通过在推理阶段将并行的多分支结构等效重参数化为单一的卷积层，RepNCSPELAN4 在不牺牲模型非线性表征能力的前提下，大幅削减了边缘设备的内存访问成本。这一设计为 YOLOv11n-MEDA 在嵌入式终端上的高频并发推理提供了底层的算力保障。

3.3.2 多尺度边缘融合与动态非单调性回归逻辑

在解决了静态微小特征的保留与传递问题后，本文进一步针对无人机机动飞行所伴随的动态模糊现象开展了专项优化。本文借鉴了 MEDA-YOLO^[19]在图像边缘提取方面的算法思想，并针对无人机低空飞行场景的物理特性，在特征输出给检测头之前引入并重新适配了 MSEF（Multi-Scale Edge Fusion）多尺度边缘增强模块^[19]。

原有的边缘检测算子多用于静态图像，而本研究为了应对不同距离下的动态拖影，在 MSEF 模块的工程实现中针对性地配置了不同尺寸的平均池化核（如 $3 \times 3, 5 \times 5$ ）对输入的局部特征进行多尺度平滑处理，以此剥离出包含背景拖影的低频特征图。随后通过计算原始特征与平滑特征之间的数学残差，模块能够显式地提取出蕴含剧烈梯度变化的高频边缘分量 ΔX_k ：

$$\Delta X_k = X_{local} - X_{pool_k} \quad (3-11)$$

在经过 1×1 卷积与激活函数的映射后，这些被捕捉到的边缘残差被转化为边缘

响应权重 E_k ，并被重新注入主干特征流中：

$$E_k = \sigma(\text{Conv}_{1 \times 1}(\Delta X_k)) \quad (3-12)$$

$$X_{enhanced} = X_{local} + X_{local} \otimes E_k \quad (3-13)$$

在模块的空间部署策略上，本文并未进行全局的冗余堆叠，而是针对无人机目标的尺度分布特性，将 MSEF 模块精准嵌合于 P2（高分辨率微小目标层）与 P5（低分辨率大感受野层）的检测头前端。在 P2 层引入 MSEF，旨在极大地增强并补偿远距离下无人机边缘的微弱高频响应；而在 P5 层引入，则用于应对无人机突然抵近侦察时产生的巨大运动模糊拖影，确保了网络在极端尺度变化下的全频段边缘感知能力。该机制的作用极其显著，即便在摄像机镜头因快速追随而导致画面出现严重拖影时，它依然能敏锐地突显出无人机微弱的旋翼和支架轮廓。

在极小目标的探测中，即使经过了 MSEF 模块的边缘增强与高分辨率 P2 层的特征保留，底层的特征图中依然会不可避免地掺杂环境背景的局部高频噪点。为了进一步提纯目标特征，本文在 P2 微小目标检测分支后创新性地引入了 EMA（Efficient Multi-Scale Attention）注意力机制模块。

与传统的 CBAM（Convolutional Block Attention Module）或 SE（Squeeze-and-Excitation）空间注意力机制不同，EMA 模块通过跨维度的交互方式，在不进行通道降维的前提下，保留了通道间的确切信息。它将特征沿两个空间维度进行池化，并利用一维卷积实现通道权重的跨空间学习。这种机制能够极其敏锐地捕捉到无人机旋翼、机臂等细长结构的像素级关联，赋予网络对无人机高频形态特征的强聚焦能力，从而在复杂的背景杂波中进一步拉升了微小目标的显著性。

3.4 算法实验环境配置与数据集构建

为了保障实验结果的绝对可复现性，本研究的所有算法训练与推理前向传播过程均在统一的高性能计算平台上完成。实验平台搭载了算力强大的图形处理单元，底层软件架构基于稳定的 Linux 操作系统以及深度学习前沿并行框架构建。

实验端配置有高性能英伟达显卡，底层软件架构基于 Ubuntu 操作系统、Python3.12 环境以及 PyTorch2.2.0 深度学习框架。具体的软硬件参数如表 3-1 所示。

本研究构建了专属的无人机多场景数据集，总计包含 5000 张高分辨率图像。数据采集涵盖了天空、楼宇、树林等多种复杂背景，并针对远距离极小目标进行了专门的过采样处理。在标注阶段，严格遵循目标轮廓边缘进行紧凑标注，并按照 8:1:1 的比例划分为训练集、验证集与测试集。

表 3-1 训练环境软硬件参数表

类别	配置项	参数规格
硬件环境	处理器（CPU）	2×Intel Xeon Platinum8273CL@2.20GHz
	图形处理器（GPU）	NVIDIA GeForce RTX3090
	显存容量	24GB(GDDR6X)
软件环境	操作系统	Ubuntu Linux
	显卡驱动版本	NVIDIA Driver550.67
	并行计算框架	CUDA12.4
	深度学习框架	PyTorch2.2.0

3.5 YOLOv11n-MEDA 算法消融实验与收敛性分析

3.5.1 改进模块的性能贡献度评估

为了验证本文提出的各个改进模块对目标检测性能的独立与协同贡献，本节在统一的实验环境与超参数设置下开展了系统性的消融实验。表 3-2 详细记录了不同算法组合在精确率、召回率以及平均精度等核心指标上的对比结果。

表 3-2 消融实验结果

实验算法	精确率/%	召回率/%	mAP50/%	mAP50:95/%
Faster R-CNN	-	-	54.5	-
YOLOv5n	93.41	94.45	95.87	56.26
YOLOv8n	93.47	93.86	95.88	55.22
YOLOv11n	93.45	93.66	95.50	54.48
YOLOv11n-CAA	92.58	93.03	95.42	53.94
YOLOv11n-CAA-Focaler	93.04	93.25	95.58	56.14
YOLOv11n-MEDA	93.30	94.26	95.95	59.07

观察表 3-2 的数据可知，作为基准的 YOLOv11n 模型在自建无人机数据集上仅取得了 95.50%的 mAP50 与 54.48%的 mAP50:95。尽管基线架构展现出了一定的基础检测潜力，但在反映高定位精度的 mAP50:95 指标上略低，且 93.66%的召回率处于相对低位。这一数据特征体现了通用检测网络在处理低空复杂空域下的微

小目标时，极易因深层语义特征的过度平滑而导致远距离目标漏检，且边界框在高交并比阈值下的回归精度严重不足。

在基线架构中首次引入上下文锚点注意力即 CAA 模块后，mAP50 指标小幅滑落至 95.42%，而 mAP50:95 亦呈现出微弱的下降趋势。从特征提取过程分析，虽然全局上下文信息的补充在理论上能增强对特征模糊目标的感知，但对于像素占比小的无人机而言，深层长距离依赖的计算往往会将背景噪声赋予较高权重，反而削弱了目标关键的边缘特征，这也从实验层面证实了单纯依靠外部模块叠加难以克服特征剥落的困难。

当进一步引入 Focaler-IoU 损失函数替代默认回归逻辑后，模型的精确率爬升至 93.04%，mAP50:95 指标亦迎来了实质性的增长。该数据的提升印证了线性区间重构机制在优化路径上的正确性。通过人为干预交并比权重的分布，该损失函数有效规避了离群困难样本引发的梯度溢出风险，迫使优化器在有限的迭代周期内实现对无人机轮廓的像素级边缘校准，从而显著降低了由定位松弛引发的虚警概率。

最终，本文提出的 YOLOv11n-MEDA 架构展现出了显著的性能优势。在集成了拓扑重构、动态上采样以及多尺度边缘融合等架构设计策略后，模型 mAP50 稳健增长至 95.95%，而表征极高定位精度的 mAP50:95 更是实现了显著提升，由基线的 54.48% 大幅提高至 59.07%，增长了 4.59%。与此同时，93.30% 的精确率与 94.26% 的召回率均处于较高水平且保持平衡。消融实验结果验证了本文研究思路的有效性，即通过将算力向浅层高分辨率特征倾斜，并配合抗扰动能力极强的难例样本重赋权回归逻辑，是攻克低空高机动微小目标精准探测难题的有效方法。




图 3-4 消融实验过程核心指标变化趋势

3.5.2 训练收敛性分析

为了直观验证本文所提改进策略的有效性,本节提取了 YOLOv11n 基线模型、引入 CAA 模块的模型、结合 Focaler-IoU 的模型,以及最终的 YOLOv11n-MEDA 架构在相同超参数下的训练日志,并绘制了四条核心指标的收敛曲线。以下从损失空间与检测精度两个维度进行重点剖析。

训练边界框损失曲线如图 3-5 所示,直观反映了模型在参数寻优过程中,对训练集无人机数据分布的拟合效率与逼近程度。该指标的绝对值大小与收敛斜率,是评估网络架构特征提取容量与优化器梯度下降有效性的核心依据。

观察图中四条曲线的全局演进轨迹,在训练的初始阶段(0~50Epochs),所有对比架构均呈现出显著的指数级下降趋势。这一现象表明,在 AdamW 优化器的动量积累与高初始学习率的驱动下,网络能够快速跨越初始化的鞍点,实现对无人机宏观轮廓特征的粗粒度拟合。然而,通过对比消融实验的四条曲线可以发现,引入 CAA 模块的 YOLOv11n-CAA 架构在早期的损失下降速率上出现了微弱的滞后,且其中后期收敛值明显高于基线模型。从特征空间的优化维度分析,CAA 模块强行拓展了深层网络的全局感受野,这不仅增加了参数空间的寻优维度,更导致网络在反向传播时吸收了大量冗余的背景噪声梯度。对于极小尺度目标而言,这种复杂的深层空间映射反而构成了优化阻碍,致使模型陷入了次优的局部极小值。

而在叠加了 Focaler-IoU 损失函数的 YOLOv11n-CAA-Focaler 曲线中,训练损失的收敛停滞现象得到了实质性的缓解,曲线重新表现出向下寻优的动能。这从数学底层印证了 Focaler-IoU 的线性区间映射机制能够有效重构梯度分布,其通过降低简单背景样本的损失权重,强迫优化器将有限的算力聚焦于回归误差较大的难例样本,从而在不改变特征图拓扑结构的前提下,最大化地增强了现有特征的拟合潜力。

最后本文所确立的 YOLOv11n-MEDA 架构在微调阶段展现出更强的损失收敛性能,其曲线在 200 轮附近平稳收敛至 1.00 左右的最低水平,实现这一深层拟合的关键在于新增的 P2 浅层高分辨率检测头最大限度保留了微小目标的像素级梯度信息,有效缓解了深层网络中常见的梯度消失,同时, MSEF 特征融合模块有效弥合了跨层传递的语义鸿沟。上述架构改进使得网络在训练后期极低学习率下,依然具备捕捉并校准亚像素级边缘偏差的能力,从而降低了边界框回归损失的理论下界。




图 3-5 消融实验训练损失 (Train Loss) 收敛过程对比

验证边界框损失曲线如图 3-6 所示,是评估模型是否发生过拟合现象以及衡量其在未见复杂场景下特征提取鲁棒性的重要依据。曲线的平滑程度与最终收敛水平,直接反映了算法在真实非受控环境中的泛化可靠性。

在 200 轮的训练过程内,四种架构的验证损失曲线整体均呈下降趋势,未出现因严重过拟合导致的 U 型回升。这一结果验证了本文所构建数据集的数据分布合理性。然而,在局部收敛特性与最终数值上,四条曲线呈现出明显差异,YOLOv11n 基线模型在 100 轮之后的微调阶段,其验证曲线出现了持续的高频震荡,这一现象表明传统的 IoU 损失函数在面对树冠重叠、光照突变等背景高度复杂的验证样本时,无法提供连续一致的惩罚梯度,导致模型在预测框精细校准过程中发生参数抖动,而 YOLOv11n-CAA 架构的验证损失相较于基线模型不仅震荡更明显,其最终收敛值亦处于最高水平,这进一步证实了深层注意力机制在微小目标检测中的泛化缺陷:模型过度拟合了训练集中的特定背景语义,一旦在验证集中遭遇未知的环境光影变化时,其目标边缘特征的判别力显著下降。

引入困难样本重赋权策略后,YOLOv11n-CAA-Focaler 的验证损失曲线表现出明显的震荡收敛特征。Focaler-IoU 通过对极端离群样本进行梯度截断,起到了类似正则化的抗扰动效果,有效抑制了验证集中极端困难样本对整体损失空间的破坏。

最后,本文提出的 YOLOv11n-MEDA 架构的验证损失曲线不仅平稳收敛至 1.50 附近,且呈现出平滑的尾部下降特征,该泛化性能的提升得益于算力向浅层特征的倾斜:剔除冗余 C2PSA 模块从根本上降低了网络对大目标深层语义特征的

过度耦合风险，而 DySample 算子与浅层 P2 检测分支的协同，使模型提取的特征更集中于目标的几何边缘。该曲线平稳且充分的收敛状态，为后续云台跟踪系统在强光、遮挡等非稳态环境下输出稳定的视觉偏差信号提供了可靠的泛化基础。




图 3-6 消融实验验证损失（Val Loss）稳定性对比

mAP50 曲线（如图 3-7 所示）是衡量模型基础召回能力与特征感知灵敏度的关键指标。在 IoU 阈值为 0.5 的条件下，预测框仅需与目标真实边界框达到 50% 的重合度即可判定为正样本，因此该指标直观反映了网络在复杂背景中提取并锁定微小无人机目标的基础能力。

从四种架构在训练初期的收敛轨迹可以看出，在 0 至 30 个 Epoch 阶段，所有模型均表现出快速的梯度下降，精度曲线以较大的斜率迅速突破 85%。这一早期快速收敛得益于无人机目标自身具备的显著结构特征，如旋翼的对称几何外形与机身的高频边缘。在训练初期，卷积网络的浅层特征提取器能够在较短的迭代周期内高效捕获这些结构信息，而当训练进入高度依赖难例样本挖掘的精细调优期后，四条曲线的变化趋势出现了明显的性能分化。YOLOv11n 基线模型在到达 95.30% 后曲线增势趋于停滞，反映出常规单阶段检测架构在处理极小尺度目标时的特征表征缺陷，即在经历多次下采样后，远距离无人机的有效空间信息被严重压缩，导致特征对齐失败。

在基线模型基础上引入 CAA 模块的 YOLOv11n-CAA 架构，其精度表现不仅未能提升，反而出现了下降，最终收敛于较低的 95.42%。从注意力机制的本质来看，CAA 模块旨在通过网络深层捕获全局的上下文长距离依赖关系。然而，对于像素占比较小的微型无人机目标，深层全局注意力的计算容易将大面积的背景环

境视为高权重特征，进而削弱甚至过滤掉目标本就微弱的边缘信息。这种特征剥落现象导致微小目标信息被宏观背景噪声覆盖，增加了漏检率。在进一步叠加 Focaler-IoU 损失函数构成的 YOLOv11n-CAA-Focaler 曲线中，精度指标呈现出扰动恢复态势，重新回升至 95.58%，印证了 Focaler-IoU 的困难样本重赋权机制，即通过优化梯度传播路径，在一定程度上强行纠正了由不当注意力机制引发的特征退化。

相比之下，本文提出的 YOLOv11n-MEDA 架构在整个训练周期内保持了最优的优化鲁棒性，最终峰值达到 95.95% 最高点。这一提升主要是因为网络自顶向下特征融合路径中对 DySample 动态上采样算子的引入，在传统 YOLO 架构中，默认的最近邻插值策略仅通过局部的像素复制来放大特征图，极易引发空间量化误差与像素棋盘效应，导致微小目标的特征点在跨层传递时发生空间位置偏移，而 DySample 算子摒弃了静态空间插值，采用基于点采样的动态学习机制，通过网络自适应回归出最优的空间采样偏移量。该机制在恢复特征图分辨率的过程中，实现了对微小无人机目标结构的亚像素级精确重构，保证了深层语义与浅层纹理对齐时的空间一致性，为该架构在检测精度上的明显优势奠定了算法基础。




图 3-7 消融实验 mAP50 收敛过程对比

mAP50:95 曲线如图 3-8 所示，综合衡量了模型在从 0.5 至 0.95、步长为 0.05 的十个 IoU 阈值下的平均精度。在本文软硬件一体化的工程背景下，该指标直接决定了视觉感知端输出至后续 PID 控制器的二维像素坐标误差是否具备足够的空间精度。

从训练初期的 0 至 30 轮次来看，四条 mAP50:95 曲线均出现了高频、大幅震

荡，该现象是优化早期多种因素耦合的必然结果，mAP 的硬阈值计算方式使预测框的微小偏移即可引起正负样本分类的突变，同时，AdamW 优化器在预热期的高学习率，以及 Mosaic 数据增强带来的批次间样本差异，进一步加剧了分类损失 (Cls Loss) 与回归损失 (Box Loss) 在反向传播早期的梯度冲突。

当训练进入平稳期后，各模块组合在精细坐标校准上的能力差异明显放大。基线模型的 mAP50:95 停滞于 54.48%，表明其预测框存在系统性的尺度膨胀或中心坐标偏移，且 YOLOv11n-CAA 曲线 mAP50:95 值进一步下降至 53.94%，该现象反映出深层注意力机制在多次下采样后对亚像素空间坐标信息的损害，导致预测框无法实现精确的几何映射。而在引入困难样本重赋权策略后，YOLOv11n-CAA-Focaler 曲线回升至 56.14%，表明 Focaler-IoU 通过截断由特征失真引发的极端空间偏差梯度，有效避免了梯度爆炸，使网络在受限的特征条件下仍能完成较为稳定的几何回归。

最终，本文提出的 YOLOv11n-MEDA 架构取得了性能上的显著优势。随着学习率余弦退火，该曲线在 150 轮之后的精细微调阶段实现二次提升，并最终在第 194 轮收敛至 59.07% 的最高值，较基线提升了 4.59 个百分点，这一结果验证了本文算法重构的有效性，即通过剔除深层 CAA 模块避免了空间分辨率的衰减，利用新增的 P2 高分辨率检测层与 MSEF 多尺度特征融合模块的协同，为坐标回归提供了高分辨率且边缘清晰的浅层特征，Focaler-IoU 则在安全梯度范围内对困难样本进行重新赋权。四条曲线的变化对比，表明将算力向浅层高分辨率特征倾斜是提升小目标定位精度的有效策略，为机电云台系统的稳态时序追踪提供了高质量的视觉前馈信号。




图 3-8 消融实验 mAP50:95 收敛过程对比


3.6 验证集检测结果定性对比分析

为了直观验证定量指标（如 mAP 与 Loss）所反映的底层网络特征表征能力，本节抽取了验证集中具有代表性的困难场景（涵盖极远距离、复杂背景干扰与低对比度环境），对 YOLOv11n 基线模型、YOLOv11n-CAA-Focaler 架构以及本文提出的 YOLOv11n-MEDA 架构的预测结果进行可视化定性对比，如图 3-9、图 3-10、图 3-11 所示。

从可视化结果的对比中可以归纳出以下三个层面的显著差异。首先是基线模型 YOLOv11n 的特征感知盲区，在面对像素占比极小的远距离无人机时，基线模型表现出明显的漏检与错检，如图 3-10（c）和图 3-11（c）所示。由于特征提取网络经过多次跨步卷积下采样，目标微弱的高频边缘信息在深层网络中被大面积的背景噪声（如树林、建筑纹理）掩盖，即便在部分对比度较高的场景下能够生成预测框，其边界框也存在明显的尺度膨胀与中心偏移，无法精确贴合目标的实际轮廓，这一现象也印证了其在 mAP50:95 指标上处于较低值的原因。


其次，YOLOv11n-CAA-Focaler 过渡架构在抗扰动能力上有所改善，但仍然存在结构缺陷。观察定性可视化结果可知，该模型在基准模型完全漏检的部分困难样本上实现了预测框的初步召回，说明 CAA 模块通过十字形条带卷积扩大感受野，在一定程度上增强了网络对弱信号目标的感知能力，同时，Focaler-IoU 损失函数对大偏差样本的梯度重赋权，也使模型初步具备跨越背景杂波的潜力。然而，定性结果分析也体现出一个问题，由于 CAA 模块过度引入长距离的空间依赖，使大量无关的背景噪声被赋予了不必要的特征权重。这种特征稀释效应导致网络在定位时容易受到无人机周围环境光影的干扰，如图 3-11（b）所示，预测框的置信度普遍偏低，且频繁将树枝间的空隙或远处的飞鸟误识别为无人机目标。这一较高的虚警率表明，在不改变网络下采样拓扑的前提下，仅靠外部注意力模块的修补，难以解决亚像素级空间细节丢失的问题。

最后本文提出的 YOLOv11n-MEDA 架构在所有困难场景中均展现出明显的视觉感知优势。定性对比结果显示，该架构不仅以高召回率检测出所有处于漏检边缘的极小目标，且预测框紧密贴合无人机的机身骨架、旋翼支架及物理边缘。该性能得益于 P2 高分辨率检测头与 DySample 动态上采样算子的跨层协同，使网络在恢复特征图空间分辨率时实现了对目标拓扑结构的亚像素级重构。该边界框空间的对齐精度与模型的 mAP50:95 指标 59.07%相符，证明了该网络拓扑重构策略在物理空间映射上的有效性，可为后续机电系统的高频姿态跟随提供高精度的视觉前馈信息。



(a) YOLOv11n-MEDA 验证集结果

(b) YOLOv11n-CAA-Focaler 验证集结果



(c) YOLOv11n 验证集结果

图 3-9 可视化检测结果对比图 1



(a) YOLOv11n-MEDA 验证集结果




(b) YOLOv11n-CAA-Focaler 验证集结果



(c) YOLOv11n 验证集结果

图 3-10 可视化检测结果对比图 2



(a) YOLOv11n-MEDA 验证集结果

(b) YOLOv11n-CAA-Focaler 验证集结果



(c) YOLOv11n 验证集结果

图 3-11 可视化检测结果对比图 3

3.7 本章小结

本章主要针对无人机探测任务中远距离微小目标的特征剥落，以及高速机动带来的动态模糊等困难，对 Yolov11 目标检测算法进行了架构重构。首先，本章探讨了基于上下文锚点注意力 CAA 与 Focaler-IoU 损失函数的初步特征增强方案，验证了其在复杂低空背景抑制中的有效性与局限性。在此基础上，为突破极小目标检测的物理限制，本文基于 MEDA-YOLO^[19] 的算法思想构建了 YOLOv11n-MEDA 高性能架构。通过重构 P2-P5 四头检测拓扑与引入 ADown、DySample 等算子，实现了高分辨率空间特征的保真传递与内容感知重采样；通过针对性地引入并适配 MSEF 多尺度边缘融合模块，有效剥离了动态模糊状态下的高频边缘残差；通过剔除深层冗余注意力机制 C2PSA 模块，阻断了网络对大目标深层语义特征的过度耦合风险；最后，采用 Focaler-IoU 损失函数重塑了边界框的回归逻辑，大幅提升了模型在应对远距离劣质样本时的抗噪能与定位稳定性。本章所完成的视觉算法架构重构，为下一章视觉-云台闭环追踪系统的工程化实现奠定了坚实的高精度感知基础。